

Tarefas: Pergunta 2

22/05/2026 – 06/06/2026

Gabriel Martins

Maio de 2026

1 Objetivo geral

Esta etapa tem como objetivo analisar como o turismo mundial esteve distribuído entre países, continentes e grupos de renda ao longo do período analisado.

A pergunta principal desta etapa é:

Como foi a distribuição do turismo global na última década?

A ideia central é verificar se o turismo foi bem distribuído entre muitos países ou se ficou concentrado em poucos destinos. Também deve ser analisado se essa concentração mudou ao longo do tempo.

O foco deve ser apenas nos dados quantitativos. Os dados qualitativos não serão usados nesta rodada.

2 Instruções gerais

- Manter todas as análises consolidadas em um único notebook.
- Sempre que possível, utilizar gráficos, tabelas e métricas estatísticas básicas:
 - média;
 - mediana;
 - desvio padrão;
 - variância;
 - mínimo e máximo;
 - quartis;
 - participação percentual;
 - proporção acumulada.
- Todas as análises principais devem ser feitas com duas bases:
 - **base original:** base sem imputação;
 - **base imputada:** base com valores faltantes preenchidos.
- A base imputada pode ser usada para melhorar a cobertura da análise, principalmente em comparações globais.
- A base original deve ser usada para validar se os padrões encontrados também aparecem nos dados observados.
- Quando o resultado for parecido nas duas bases, considerar o resultado mais robusto.
- Quando o resultado mudar bastante entre a base original e a base imputada, registrar que o resultado é sensível à imputação.
- Em rankings, indicar quando um país aparece com valores imputados.
- Ao final de cada tarefa, escrever uma pequena interpretação dos resultados.

3 Tarefas

3.1 1. Análise da distribuição por continente e grupo de renda

Objetivo

Verificar como as principais métricas de turismo estão distribuídas entre continentes e grupos de renda.

O que fazer

Calcular a participação percentual de cada continente e de cada grupo de renda nas principais variáveis:

- `Arrivals`;
- `Receipts`;
- `Expenditures`;
- `Receipts_per_Arrival`;
- `Tourism_Balance`.

Para cada variável, calcular por continente e grupo de renda:

- soma total;
- média;
- mediana;
- desvio padrão;
- variância;
- participação percentual no total global;
- evolução da participação ao longo dos anos.

Visualizações esperadas

- gráfico de barras com participação de cada continente em `Arrivals`;
- gráfico de barras com participação de cada continente em `Receipts`;
- gráfico de barras com participação de cada grupo de renda em `Receipts`;
- gráfico de linha mostrando a evolução da participação dos continentes ao longo do tempo;
- boxplots das variáveis principais por continente;
- boxplots das variáveis principais por grupo de renda;
- tabela-resumo com estatísticas descritivas por continente e grupo de renda.

Uso da base original e da base imputada

- Fazer os gráficos principais com a base imputada.
- Repetir as principais tabelas e gráficos com a base original.
- Comparar se os mesmos continentes e grupos de renda aparecem como dominantes nas duas bases.
- Para `Arrivals`, a base imputada tende a ser menos problemática, pois havia menos valores faltantes.
- Para `Receipts` e `Expenditures`, ter mais cuidado, pois essas variáveis tinham mais valores faltantes.
- Se a participação de um continente ou grupo mudar muito entre as bases, registrar isso na conclusão.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

Quais continentes e grupos de renda concentram a maior parte das chegadas, receitas e gastos turísticos?

3.2 2. Análise de concentração por país

Objetivo

Verificar se poucos países concentram grande parte do turismo mundial.

O que fazer

Para cada ano, calcular:

- participação dos 5 maiores países;
- participação dos 10 maiores países;
- participação dos 20 maiores países;
- participação acumulada dos países ordenados do maior para o menor;
- ranking dos países por **Arrivals**;
- ranking dos países por **Receipts**;
- ranking dos países por **Expenditures**.

As variáveis principais da análise são:

- **Arrivals**;
- **Receipts**;
- **Expenditures**.

Visualizações esperadas

- gráfico de barras com os 10 países com maior número de chegadas;
- gráfico de barras com os 10 países com maior receita turística;
- gráfico de barras com os 10 países com maiores gastos turísticos;
- gráfico de linha mostrando a participação do top 10 ao longo do tempo;
- gráfico de linha mostrando a participação do top 5, top 10 e top 20;
- curva acumulada mostrando quanto os maiores países concentram do total global;
- tabela com os países que mais aparecem no top 10 ao longo do período.

Uso da base original e da base imputada

- Rankings devem ser feitos com muito cuidado, pois são sensíveis à imputação.
- Fazer rankings com a base imputada e com a base original.
- Nos rankings da base imputada, marcar países que possuem valores imputados na variável usada.
- Para cada top 10, indicar quantos países possuem valor imputado.
- Se um país só aparece no top 10 por causa da imputação, registrar isso.
- Se o padrão geral de concentração se mantiver nas duas bases, considerar a conclusão mais robusta.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

O turismo mundial está concentrado em poucos países? Essa concentração mudou ao longo do tempo?

3.3 3. Métricas formais de desigualdade e concentração

Objetivo

Medir a concentração do turismo com métricas estatísticas, não apenas com gráficos e rankings.

O que fazer

Calcular, para cada ano, métricas de concentração para:

- Arrivals;
- Receipts;
- Expenditures.

Métricas sugeridas:

- participação do top 5;
- participação do top 10;
- participação do top 20;
- razão entre o percentil 90 e o percentil 50;
- razão entre o percentil 75 e o percentil 25.

Visualizações esperadas

- gráfico de linha da participação do top 10 ao longo do tempo;
- tabela com as métricas de concentração por ano;
- comparação entre concentração de Arrivals e concentração de Receipts.

Uso da base original e da base imputada

- Calcular todas as métricas na base imputada.
- Calcular todas as métricas na base original.
- Se a base imputada mostrar queda de concentração, mas a base original não mostrar, registrar que a conclusão é sensível.
- Se a imputação reduzir artificialmente a desigualdade, isso deve ser comentado.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

A distribuição do turismo ficou mais concentrada ou mais diversificada ao longo do período?

3.4 4. Teste de hipótese com simulação: concentração no top 10

Objetivo

Testar se a concentração observada nos 10 principais países é maior do que seria esperado em uma distribuição menos concentrada.

Pergunta do teste

Os 10 principais países concentram uma parcela anormalmente alta do turismo mundial?

Hipóteses

Para cada variável principal, testar:

- **H0:** a concentração observada no top 10 não é maior do que seria esperado por uma distribuição aleatória entre países.
- **H1:** a concentração observada no top 10 é maior do que seria esperado por uma distribuição aleatória entre países.

Variáveis analisadas

Aplicar para:

- Arrivals;
- Receipts;
- Expenditures.

Como fazer a simulação

Para cada ano e variável:

1. Calcular a participação real do top 10 no total global.
2. Embaralhar os valores da variável entre os países.
3. Recalcular a participação do top 10 na base embaralhada.
4. Repetir o processo 5.000 ou 10.000 vezes.
5. Comparar a participação real do top 10 com a distribuição simulada.

O que reportar

Para cada variável, reportar:

- participação real média do top 10;
- média da participação simulada;
- mediana da participação simulada;
- desvio padrão da distribuição simulada;
- p-valor empírico;
- conclusão do teste;
- interpretação em linguagem simples.

O p-valor pode ser calculado como:

proporção de simulações em que `top10_simulado >= top10_real`

Visualizações esperadas

- histograma da distribuição simulada da participação do top 10;
- linha vertical indicando a participação real do top 10;
- gráfico de linha da participação real do top 10 ao longo do tempo;
- tabela com os p-valores por ano e variável.

Uso da base original e da base imputada

- Rodar a simulação com a base imputada.
- Rodar a simulação com a base original.
- Comparar os p-valores e a participação real do top 10.
- Se a concentração for significativa nas duas bases, considerar a conclusão robusta.
- Se a concentração só aparecer na base imputada, registrar que o resultado depende da imputação.
- Ter cuidado especial com **Receipts** e **Expenditures**, pois rankings financeiros podem ser afetados por valores imputados.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

A concentração nos maiores países é estatisticamente relevante ou é apenas um efeito esperado da variação normal dos dados?

3.5 5. Testes A/B entre grupos

Objetivo

Comparar se alguns grupos de países concentram mais turismo do que outros.

Comparações sugeridas

Realizar pelo menos duas das comparações abaixo:

- **Alta renda vs demais países**
 - Grupo A: países de alta renda.
 - Grupo B: demais países.
- **Europa vs resto do mundo**
 - Grupo A: países da Europa.
 - Grupo B: países de outros continentes.
- **Top 10 vs demais países**
 - Grupo A: países que aparecem no top 10.
 - Grupo B: países fora do top 10.

Variáveis analisadas

Comparar os grupos usando:

- Arrivals;
- Receipts;
- Expenditures;
- Receipts_per_Arrival;
- Arrivals_per_Population;
- Tourism_Balance.

Testes sugeridos

Usar pelo menos um teste paramétrico e um não paramétrico:

O que reportar

Para cada comparação, reportar:

- média do Grupo A;
- média do Grupo B;
- mediana do Grupo A;
- mediana do Grupo B;
- desvio padrão de cada grupo;
- diferença entre médias;
- diferença entre medianas;
- p-valor;
- interpretação.

Visualizações esperadas

- boxplot comparando os grupos;
- violin plot ou histograma por grupo;
- gráfico de barras com médias e intervalos de confiança;
- tabela com os resultados dos testes.

Uso da base original e da base imputada

- Rodar os testes com a base imputada.
- Rodar os testes com a base original.
- Comparar se as diferenças entre grupos aparecem nas duas bases.
- Se a diferença for forte apenas na base imputada, tratar o resultado como sensível.
- Se muitos valores de uma variável estiverem imputados em um grupo, mencionar isso.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

Alguns grupos de países têm participação muito maior no turismo global do que outros?

3.6 6. Análise de risco e dependência turística

Objetivo

Identificar países que dependem muito do turismo ou que recebem turistas em proporção muito alta em relação ao seu tamanho.

O que fazer

Analisar as seguintes variáveis:

- Receipts - % of Total Exports;
- Expenditures - % of Total Imports;
- Arrivals_per_Population;
- Tourism_Balance;
- volatilidade de Receipts;
- volatilidade de Arrivals.

Criar indicadores simples:

- país com alta dependência turística: alto valor em Receipts - % of Total Exports;
- país com alta intensidade turística: alto valor em Arrivals_per_Population;
- país com alto risco turístico: alta dependência e alta volatilidade.

Critérios sugeridos

Usar percentis para definir grupos:

- alta dependência: acima do percentil 75;
- dependência muito alta: acima do percentil 90;
- alta intensidade turística: acima do percentil 75;
- alta volatilidade: acima do percentil 75.

Visualizações esperadas

- ranking dos países com maior dependência turística;
- ranking dos países com maior número de turistas por habitante;
- scatter plot entre dependência turística e volatilidade;
- scatter plot entre Arrivals_per_Population e Receipts - % of Total Exports;
- tabela com países classificados como alto risco turístico.

Uso da base original e da base imputada

- Essa análise é sensível à imputação, pois usa variáveis percentuais que tinham mais valores faltantes.
- Fazer a análise com a base imputada, mas validar rankings principais com a base original.
- Marcar países em que a variável de dependência foi imputada.
- Não tirar conclusões fortes sobre um país específico se a posição dele depender de valor imputado.
- Usar a base imputada para identificar padrões gerais, não para afirmar com certeza o risco de um país individual.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

Quais países parecem mais dependentes do turismo e mais expostos a riscos no setor?

4 Resumo das entregas esperadas

Ao final da rodada, o notebook deve conter:

- tabelas com estatísticas descritivas por continente;
- tabelas com estatísticas descritivas por grupo de renda;
- gráficos de participação por continente;
- gráficos de participação por grupo de renda;
- rankings de países por **Arrivals**, **Receipts** e **Expenditures**;
- análise da participação do top 5, top 10 e top 20;
- curva acumulada de concentração;
- métricas de concentração, como Gini e HHI;
- teste com simulação para concentração no top 10;
- testes A/B entre grupos;
- análise de dependência e risco turístico;
- comparação entre base original e base imputada;
- conclusões escritas em linguagem simples.

5 Conclusões que devem ser escritas no notebook

No final do notebook, incluir uma seção chamada:

Conclusão da Pergunta 2

Essa seção deve responder diretamente:

- Como o turismo global está distribuído entre continentes?
- Como o turismo global está distribuído entre grupos de renda?
- Poucos países concentram grande parte das chegadas e receitas?
- A concentração aumentou ou diminuiu ao longo do tempo?
- A concentração é maior em **Arrivals**, **Receipts** ou **Expenditures**?
- Existem países com forte dependência turística?
- A conclusão muda quando usamos a base original em vez da imputada?
- A imputação afetou rankings ou métricas de concentração?

A resposta final deve ser curta, clara e baseada nos resultados dos gráficos, tabelas e testes.

6 Cuidados com a base imputada

A base imputada pode ser usada, mas alguns cuidados são necessários:

- Não tratar valores imputados como se fossem valores observados.
- Sempre comparar os principais resultados com a base original.
- Rankings são muito sensíveis à imputação.
- Em rankings, indicar se os países do topo possuem valores imputados.
- Métricas de concentração podem mudar se muitos valores financeiros forem imputados.
- Em análises de dependência turística, ter cuidado com variáveis percentuais imputadas.
- Se uma conclusão aparecer apenas na base imputada, escrever que ela é sensível à imputação.
- Dar mais peso a conclusões que aparecem tanto na base original quanto na base imputada.

7 Recados

- Não enviar diretamente para a branch `main`. Trabalhar sempre em sua própria branch.
- Mesmo que algo vá para a `main`, será apenas parte do trabalho, não a versão final.
- As tarefas descritas são necessárias, mas não suficientes. Descobertas adicionais devem ser registradas no `README`.
- Ao concluir as tarefas, avisar no grupo.
- Caso não consiga finalizar no prazo, avisar com antecedência.
- Utilizar visualizações claras sempre que possível.
- Manter o notebook organizado, com títulos, comentários e conclusões parciais.