

Tarefas: Pergunta 3

22/05/2026 – 06/06/2026

Gabriel Martins

Maio de 2026

1 Objetivo geral

Esta etapa tem como objetivo investigar se receber mais turistas significa, necessariamente, ter melhor desempenho turístico.

A pergunta principal desta etapa é:

Mais turistas necessariamente significam melhor desempenho turístico?

A ideia é comparar volume de turistas com retorno financeiro e desempenho líquido. Um país pode receber muitos turistas, mas ainda assim ter baixa receita por turista, muitos gastos de residentes no exterior ou uma balança turística ruim.

O foco deve ser apenas nos dados quantitativos. Os dados qualitativos não serão usados nesta rodada.

2 Instruções gerais

- Manter todas as análises consolidadas em um único notebook.
- Sempre que possível, utilizar gráficos, tabelas e métricas estatísticas básicas:
 - média;
 - mediana;
 - desvio padrão;
 - variância;
 - mínimo e máximo;
 - quartis;
 - correlação;
 - erro médio absoluto;
 - erro quadrático médio;
 - R^2 .
- Todas as análises principais devem ser feitas com duas bases:
 - **base original**: base sem imputação;
 - **base imputada**: base com valores faltantes preenchidos.
- A base imputada pode ser usada para aumentar a cobertura da análise.
- A base original deve ser usada para verificar se as conclusões principais também aparecem nos dados observados.
- Quando o resultado for parecido nas duas bases, considerar o resultado mais robusto.
- Quando o resultado mudar bastante entre a base original e a base imputada, registrar que o resultado é sensível à imputação.
- Em modelos de regressão, evitar usar como variável alvo valores imputados.
- Ao final de cada tarefa, escrever uma pequena interpretação dos resultados.

3 Tarefas

3.1 1. Engenharia de atributos de desempenho turístico

Objetivo

Criar ou revisar variáveis que ajudem a medir desempenho turístico além do número bruto de turistas.

O que fazer

Criar ou revalidar as seguintes variáveis:

- `Receipts_per_Arrival`: receita por turista;
- `Tourism_Balance`: receitas menos gastos turísticos;
- `Receipts_Expenditures_Ratio`: razão entre receitas e gastos;
- `Arrivals_per_Population`: turistas por habitante;
- `Receipts_per_Population`: receita turística por habitante;
- `Arrivals_Growth`: crescimento anual de chegadas;
- `Receipts_Growth`: crescimento anual de receitas;
- `Balance_Growth`: crescimento anual da balança turística;
- `Receipts_Volatility`: volatilidade anual das receitas;
- `Arrivals_Volatility`: volatilidade anual das chegadas.

Cuidados

- Evitar divisões por zero.
- Tratar valores infinitos como nulos.
- Verificar se há valores extremos muito grandes.
- Usar escala logarítmica quando houver muita assimetria.
- Documentar no notebook como cada variável foi criada.

Visualizações esperadas

- tabela com exemplos das variáveis criadas;
- histogramas de `Receipts_per_Arrival`, `Tourism_Balance` e `Arrivals_per_Population`;
- boxplots das principais métricas de desempenho;
- tabela com estatísticas descritivas das novas variáveis.

Uso da base original e da base imputada

- Criar as variáveis nas duas bases.
- Na base imputada, manter ou criar marcadores indicando se a variável derivada depende de algum valor imputado.
- Exemplo: se `Receipts` foi imputado, então `Receipts_per_Arrival` deve ser marcada como dependente de imputação.
- Variáveis derivadas com muitos valores imputados devem ser interpretadas com mais cuidado.
- Para análises de ranking, indicar quando a métrica depende de imputação.

Resultado esperado

Ao final desta tarefa, deve haver uma base preparada para comparar volume de turistas, retorno financeiro e desempenho líquido.

3.2 2. Análise exploratória: volume versus desempenho

Objetivo

Comparar o número de turistas com métricas de desempenho econômico.

O que fazer

Analisar a relação entre:

- Arrivals e Receipts;
- Arrivals e Receipts_per_Arrival;
- Arrivals e Tourism_Balance;
- Arrivals e Receipts_Expenditures_Ratio;
- Arrivals_per_Population e Receipts_per_Arrival.

Também comparar rankings:

- top 10 países por Arrivals;
- top 10 países por Receipts;
- top 10 países por Receipts_per_Arrival;
- top 10 países por Tourism_Balance;
- países que recebem muitos turistas, mas têm baixo desempenho relativo.

Visualizações esperadas

- scatter plot de Arrivals versus Receipts;
- scatter plot de Arrivals versus Receipts_per_Arrival;
- scatter plot de Arrivals versus Tourism_Balance;
- gráficos em escala logarítmica para Arrivals e Receipts;
- rankings comparando países por volume e por eficiência;
- matriz de correlação das variáveis de desempenho.

Uso da base original e da base imputada

- Fazer a EDA principal com a base imputada.
- Repetir os principais scatter plots e rankings com a base original.
- Marcar nos rankings os países que dependem de variáveis imputadas.
- Se os rankings mudarem muito entre as duas bases, registrar que a conclusão é sensível à imputação.
- Para conclusões sobre países específicos, dar preferência aos valores observados.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

Países que recebem mais turistas também são os que têm melhor retorno financeiro e melhor saldo turístico?

3.3 3. Análise de correlação

Objetivo

Medir a força da relação entre volume de turistas e desempenho turístico.

O que fazer

Calcular correlações entre:

- Arrivals e Receipts;
- Arrivals e Receipts_per_Arrival;
- Arrivals e Tourism_Balance;
- Arrivals e Expenditures;
- Receipts e Expenditures;
- Receipts_per_Arrival e Tourism_Balance.

Usar dois tipos de correlação:

- Pearson, para relação linear;
- Spearman, para relação monotônica e comparação de rankings.

O que reportar

Para cada par de variáveis, reportar:

- correlação de Pearson;
- p-valor de Pearson;
- correlação de Spearman;
- p-valor de Spearman;
- número de observações usadas;
- interpretação.

Visualizações esperadas

- matriz de correlação;
- heatmap de correlação;
- scatter plots com linha de tendência;
- comparação entre correlação na base original e na imputada.

Uso da base original e da base imputada

- Calcular correlações com a base imputada.
- Calcular correlações com a base original.
- Comparar se os sinais e magnitudes das correlações são parecidos.
- Se a correlação for muito maior na base imputada, registrar que a imputação pode ter aumentado artificialmente a relação.
- Dar mais peso às correlações que aparecem de forma parecida nas duas bases.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

O número de turistas está fortemente relacionado com receitas, eficiência e saldo turístico?

3.4 4. Teste A/B: países com muitos turistas têm melhor desempenho?

Objetivo

Comparar países com alto volume de turistas com os demais países.

Definição dos grupos

Criar dois grupos:

- **Grupo A:** países no top 25% de `Arrivals`;
- **Grupo B:** demais países.

Também pode ser feita uma análise complementar com:

- top 10 países por `Arrivals`;
- países fora do top 10.

Variáveis comparadas

Comparar os grupos usando:

- `Receipts`;
- `Receipts_per_Arrival`;
- `Tourism_Balance`;
- `Receipts_Expenditures_Ratio`;
- `Receipts_per_Population`.

Hipóteses

Para cada métrica de desempenho:

- **H0:** países com muitos turistas têm desempenho igual ou menor que os demais.
- **H1:** países com muitos turistas têm desempenho maior que os demais.

Se a métrica for `Receipts_per_Arrival`, considerar também hipótese bilateral, pois países com muitos turistas podem ter maior ou menor receita por turista.

O que reportar

Para cada comparação, reportar:

- média do Grupo A;
- média do Grupo B;
- mediana do Grupo A;
- mediana do Grupo B;
- desvio padrão dos grupos;
- diferença entre médias;

- diferença entre medianas;
- p-valor;
- intervalo de confiança da diferença;
- interpretação.

Visualizações esperadas

- boxplots comparando Grupo A e Grupo B;
- gráficos de barras com médias e intervalos de confiança;
- tabela com os resultados dos testes;
- ranking dos países do Grupo A com melhor e pior desempenho.

Uso da base original e da base imputada

- Rodar os testes com a base imputada.
- Rodar os testes com a base original.
- Na base imputada, marcar se a variável de desempenho usada no teste depende de valores imputados.
- Se a diferença entre grupos só aparecer na base imputada, tratar o resultado como sensível.
- Para conclusões fortes, exigir que a direção do resultado seja parecida nas duas bases.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

Países com muitos turistas têm desempenho econômico melhor ou apenas maior volume?

3.5 5. Regressão: prever receitas a partir do volume de turistas

Objetivo

Avaliar quanto das receitas turísticas pode ser explicado pelo número de turistas e por outras características quantitativas.

Modelo principal

Criar um modelo de regressão para prever:

$\log(\text{Receipts})$

Variáveis explicativas sugeridas:

- $\log(\text{Arrivals})$;
- $\log(\text{Population})$;
- Year;
- Continent;
- IncomeGroup;
- Arrivals_per_Population.

Modelos sugeridos

Rodar pelo menos:

- regressão linear simples:

$$\log(\text{Receipts}) \sim \log(\text{Arrivals})$$

- regressão linear múltipla:

$$\log(\text{Receipts}) \sim \log(\text{Arrivals}) + \log(\text{Population}) + \text{Year} + \text{Continent} + \text{IncomeGroup}$$

Avaliação

Avaliar os modelos usando:

- R^2 ;
- erro médio absoluto, MAE;
- raiz do erro quadrático médio, RMSE;
- análise dos resíduos;
- comparação entre modelo simples e modelo múltiplo.

Análise de resíduos

Depois da regressão, identificar:

- países com receita observada muito acima da receita prevista;
- países com receita observada muito abaixo da receita prevista;
- países que monetizam melhor o turismo do que o esperado;
- países que recebem muitos turistas, mas geram menos receita do que o esperado.

Visualizações esperadas

- gráfico de valores reais versus valores previstos;
- gráfico de resíduos;
- ranking dos maiores resíduos positivos;
- ranking dos maiores resíduos negativos;
- tabela com métricas de avaliação dos modelos;
- comparação entre modelo simples e modelo múltiplo.

Uso da base original e da base imputada

- A regressão pode usar a base imputada para aumentar cobertura, mas isso deve ser feito com cuidado.
- Evitar treinar o modelo usando **Receipts** imputado como variável alvo.
- Rodar o modelo principal apenas com linhas em que **Receipts** não foi imputado.
- Como análise complementar, rodar o modelo com a base imputada completa.
- Comparar os resultados dos dois modelos.
- Se o modelo com base imputada tiver desempenho muito melhor, verificar se isso não ocorreu porque a imputação deixou os dados mais estáveis.
- Incluir variáveis indicadoras de imputação como controle, se possível.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

O número de turistas explica bem as receitas turísticas? Quais países ficam acima ou abaixo do esperado?

3.6 6. Classificação simples de desempenho turístico

Objetivo

Criar uma classificação simples para separar países com alto e baixo desempenho turístico.

Variável alvo sugerida

Criar uma variável chamada:

High_Performance

Uma definição possível:

- `High_Performance = 1` se:
 - `Tourism_Balance > 0`;
 - `Receipts_per_Arrival` acima da mediana mundial;
 - `Receipts_Expenditures_Ratio > 1`.
- `High_Performance = 0` caso contrário.

Uma definição alternativa mais simples:

- `Surplus = 1` se `Tourism_Balance > 0`;
- `Surplus = 0` se `Tourism_Balance <= 0`.

Variáveis explicativas sugeridas

Usar como preditores:

- Arrivals;
- Receipts_per_Arrival;
- Arrivals_per_Population;
- Receipts - % of Total Exports;
- Expenditures - % of Total Imports;
- Population;
- Year;
- Continent;
- IncomeGroup;

Modelos sugeridos

Rodar pelo menos um modelo simples:

- regressão logística;

Avaliação

Avaliar o modelo usando:

- acurácia;
- precisão;
- recall;
- F1-score;
- matriz de confusão;
- ROC-AUC, se aplicável.

Cuidados com a variável alvo

- A variável alvo não deve depender de valores imputados sem controle.
- Se `Tourism_Balance` usa `Receipts` ou `Expenditures` imputados, marcar a linha como alvo menos confiável.
- O modelo principal deve ser treinado apenas com alvos confiáveis.
- A base imputada pode ser usada como análise complementar.

Visualizações esperadas

- matriz de confusão;
- tabela com métricas de classificação;
- gráfico de importância das variáveis, se usar árvore ou Random Forest;
- comparação de desempenho entre modelos, se mais de um for usado.

Uso da base original e da base imputada

- Rodar o modelo principal com linhas em que a variável alvo não depende de imputação.
- Rodar um modelo complementar com a base imputada completa.
- Comparar as métricas dos dois modelos.
- Se o modelo com base imputada ficar muito melhor, investigar se a imputação facilitou artificialmente a classificação.
- Não tirar conclusões fortes a partir de alvos criados com muitos valores imputados.

Resultado esperado

Ao final desta tarefa, deve ser possível responder:

É possível classificar países com alto desempenho turístico usando apenas variáveis quantitativas?

4 Resumo das entregas esperadas

Ao final da rodada, o notebook deve conter:

- variáveis derivadas de desempenho turístico;
- tabelas com estatísticas descritivas das variáveis criadas;
- gráficos comparando volume de turistas e receitas;
- rankings por volume e por eficiência;
- análise de correlação usando Pearson e Spearman;
- testes A/B entre países com muitos turistas e demais países;
- regressão para prever receitas turísticas;
- análise de resíduos da regressão;
- classificação simples de desempenho turístico;
- comparação entre base original e base imputada;
- conclusões escritas em linguagem simples.

5 Conclusões que devem ser escritas no notebook

No final do notebook, incluir uma seção chamada:

Conclusão da Pergunta 3

Essa seção deve responder diretamente:

- Países que recebem mais turistas também geram mais receitas?
- Mais turistas significam maior receita por turista?
- Mais turistas significam melhor balança turística?
- Quais métricas mostram melhor desempenho turístico além de **Arrivals**?
- O número de turistas explica bem as receitas no modelo de regressão?
- Quais países ficam acima ou abaixo do esperado na regressão?
- Foi possível classificar países com alto desempenho turístico?
- A conclusão muda quando usamos a base original em vez da imputada?
- A imputação afetou muito os resultados?

A resposta final deve ser curta, clara e baseada nos resultados dos gráficos, tabelas, testes e modelos.

6 Cuidados com a base imputada

A base imputada pode ser usada, mas alguns cuidados são necessários:

- Não tratar valores imputados como se fossem valores observados.
- Sempre comparar os principais resultados com a base original.
- Variáveis derivadas podem carregar erro de imputação.
- Em rankings, indicar se a métrica depende de valores imputados.
- Na regressão, evitar usar **Receipts** imputado como alvo principal.

- Na classificação, evitar criar alvo com **Tourism_Balance** se ele depender de **Receipts** ou **Expenditures** imputados.
- Se uma conclusão aparecer apenas na base imputada, escrever que ela é sensível à imputação.
- Dar mais peso a conclusões que aparecem tanto na base original quanto na base imputada.

7 Recados

- Não enviar diretamente para a branch **main**. Trabalhar sempre em sua própria branch.
- Mesmo que algo vá para a **main**, será apenas parte do trabalho, não a versão final.
- As tarefas descritas são necessárias, mas não suficientes. Descobertas adicionais devem ser registradas no **README**.
- Ao concluir as tarefas, avisar no grupo.
- Caso não consiga finalizar no prazo, avisar com antecedência.
- Utilizar visualizações claras sempre que possível.
- Manter o notebook organizado, com títulos, comentários e conclusões parciais.